v0.1 · 2026-11

给企业团队的 15 个硬问题

AI 落地自查清单

不问你懂不懂 AI，只问这件事能不能落地。

不评估模型参数，不讨论技术趋势。只回答一个问题：这个 AI 场景在你们公司， 现在能不能做、做完能不能上线、上线后能不能兜住。

01	业务价值	这件事值不值得做，谁对结果负责	A1–A3
02	数据与权限	数据能不能用，权限会不会越界	B1–B3
03	模型与提示词	效果是否可控，系统是否可维护	C1–C3
04	评测与验收	做到什么程度算完成，由谁来签字	D1–D3
05	上线与运维	出了问题能不能回滚、能不能兜底	E1–E3

15 条检查项 · 5 个维度 · 0/1 打分 · 30–45 分钟

适用：企业技术负责人 / 产品经理 / 项目负责人

用法：3–5 人各自打分，再集中校准分歧

业务价值 × 数据与权限

先判断值不值得做
再判断能不能安全地做

01 业务价值 A1–A3

A1 能不能用一句话说清“谁、在什么环节、把什么输入变成什么输出”?

检查问题 这个 AI 场景服务哪个岗位？在哪个业务流程的哪一步？输入是什么、输出是什么、多久发生一次?

为什么重要 企业 AI 项目失败，多数不是模型不行，而是场景太宽。“提升效率”“赋能业务”无法验收，也无法判断该不该做。场景越具体，越能算账、选型、评测。

通过标准 能用“岗位 + 环节 + 输入 + 输出 + 频率”完整描述；访谈过至少 3 名一线使用者；该动作每周发生不少于 5 次，或能对应明确的金额/风险损失。

危险信号 需求文档里只有“降本增效、全面智能化”；不同部门对同一个场景理解不一致；只有领导觉得需要，一线说不出痛在哪里。

A2 投入产出账能不能算清，哪怕只是粗算?

检查问题 一次性开发、模型调用、数据处理、集成、运维、人工复核各要多少成本？一年能省多少工时或增加多少收入？多久回本?

为什么重要 AI 不是一次性采购。token、向量库、评测、人工兜底都是持续成本。算不清账的项目，最后通常死在预算会，而不是技术评审。

通过标准 有一张单场景成本表，覆盖一次性投入与月度运行成本；有当前人工处理成本或业务损失作基线；回收期不超过 12 个月，或明确写为战略投入并设止损线。

危险信号 只算模型 API 单价，不算集成和人力；用“以后规模大了就便宜”解释当前不划算；没人能说出现在的基线成本。

A3 有没有一个能对业务结果负责的 Owner?

检查问题 项目谁发起、谁使用、谁验收？效果不好时谁拍板停用或调整？预算和流程由谁协调?

为什么重要 AI 项目横跨业务、IT、数据、安全。没有业务 Owner，项目就会变成技术部门的自嗨：上线没人用，验收没人签字，出问题没人负责。

通过标准 指定一位业务负责人（能调动流程和预算）和一位技术负责人；验收人、停用决策人明确到姓名或岗位；业务负责人参与需求评审和验收。

危险信号 项目挂在“创新小组”但业务部门不认领；需求由 IT 单方面提出；出了问题上交老板临时裁决。

02 数据与权限 B1–B3

B1 数据从哪里来、多久更新、谁负责，能不能说清?

检查问题 模型要用哪些数据？来自哪些系统或文件？更新频率是多少？数据质量由谁负责？过期数据怎么处理?

为什么重要 RAG 和微调的效果上限由数据决定。企业数据通常分散、过期、口径不一。说不清来源，就解释不了错误，也无法长期维护。

通过标准 有数据源清单（系统、表/文档、字段、负责人、更新频率）；关键数据有唯一事实源；过期数据有自动刷新或定期巡检机制。

危险信号 “把公司文档都传上去”；数据靠个人网盘、聊天记录手工收集；没人能回答某条数据是什么时候更新的。

B2 权限是否按最小必要隔离，并继承源系统的权限?

检查问题 员工 A 通过 AI 能不能看到员工 B 无权查看的内容？权限是在检索前过滤，还是生成后靠提示词约束?

为什么重要 企业 AI 最大的事故不是答错，是越权泄露。把全公司文档灌进一个共享知识库，是最常见、也最难补救的埋雷方式。

通过标准 检索阶段按用户身份做文档级/字段级过滤；权限与源系统 ACL 同步；有越权测试用例并通过；离职、转岗权限当日回收。

危险信号 所有人共用一个 API Key 或服务账号；向量库没有权限字段；靠“请不要回答无权内容”这类提示词防越权。

B3 数据合规评估做完了吗：个人信息、敏感数据、跨境传输?

检查问题 数据里有没有个人信息、客户资料、合同、财务数据？数据是否出境？模型供应商是否会把数据用于训练？保留多久?

为什么重要 这是法律和信任的底线。合规问题不是技术故障，而是公司级风险；上线后再补，成本通常高一个量级。

通过标准 完成数据分类分级；敏感数据脱敏或不出域；与供应商确认数据不用于训练、存储地域和保留期限；有法务或安全部门的书面确认。

危险信号 直接把生产库导出给公有云模型；用境外 API 处理客户个人信息且未做评估；供应商协议里找不到数据处理条款。

模型与提示词 × 评测与验收

效果不是“感觉不错”
而是可评测、可验收

03 模型与提示词 C1–C3

C1 模型选型有依据，而且随时能换吗？

检查问题 为什么选这个模型？是同一批真实任务评测出来的，还是因为名气、顺手、别人推荐？换模型需要改多少代码？

为什么重要 模型能力、价格和可用性每个月都在变。把业务绑死在一个模型或一个供应商上，半年后就会失去议价和调整空间。

通过标准 有 2–3 个候选模型在同一批真实任务上的对比记录（准确率、延迟、成本）；模型调用封装在统一接口层，切换模型不超过 1 人天；有备用模型或降级方案。

危险信号 选型理由是“别人都在用”；模型 SDK 散落在大量业务代码里；没有延迟和成本监控。

C2 提示词是否版本化、可回归，并限定了输入输出边界？

检查问题 提示词存在哪里？谁改过、改了什么、为什么改？改完怎么验证没有变差？模型会不会被用户套出系统提示或执行越权指令？

为什么重要 提示词是企业 AI 的业务逻辑。散落在代码字符串或员工电脑里，就无法维护；没有回归测试，改一个字可能让准确率明显下降。

通过标准 提示词统一存放在版本库或配置中心，有版本号和变更记录；关键提示词配 20–50 条回归用例；输入输出有结构约束（如 JSON Schema）和长度限制；对提示注入有防护和测试。

危险信号 提示词靠复制粘贴在群里传；改完直接上线不测试；把数据库连接串、内部 URL、密钥写进系统提示。

C3 模型不确定、答错、超时或限流时，系统怎么兜底？

检查问题 模型答不上来怎么办？答案置信度低怎么办？接口超时或限流怎么办？高风险动作有没有人工确认？

为什么重要 大模型永远有幻觉概率。企业场景的关键不是追求 100% 正确，而是让错误可发现、可拦截、可恢复。

通过标准 定义置信度阈值和转人工规则；付款、删数据、对外发送等高风险动作必须二次确认；超时和限流有明确降级路径；所有兜底路径都测试过。

危险信号 模型输出直接触发业务动作；没有人工复核环节；出错时只提示“系统繁忙”，不告诉用户下一步怎么办。

04 评测与验收 D1–D3

D1 有没有一份来自真实业务的评测集？

检查问题 上线前拿什么证明“能用”？测试用例来自真实工单、真实对话、真实文档，还是开发自己编的？覆盖了多少边界和异常情况？

为什么重要 没有评测集，验收只能靠感觉。Demo 里挑几个好例子都能通过，真实流量一上来就露馅；而且没有基线，后续迭代无法判断是否退步。

通过标准 评测集不少于 100 条（冷启动阶段至少 50 条），来自真实业务，覆盖正常、边界、恶意输入；有标准答案和评分规则；评测集与调参集分离，避免反复调参污染。

危险信号 测试题全是“请介绍一下……”；评测人只有开发自己；没有记录错误类型分布，只记录一个总分。

D2 验收指标写进项目书了吗，口径是否可量化？

检查问题 准确率、召回率、采纳率、人工节省时长、业务转化，各定多少？谁来测、怎么算、什么时候算？达不到怎么办？

为什么重要 “效果好”不是验收标准。没有量化口径，上线后业务说不行、技术说行，最后只能靠职位高低决定，项目无法复盘。

通过标准 每个指标有定义、计算公式、目标值、测量方法和责任人；区分模型指标与业务指标；验收在真实用户、真实流量下进行；未达标有整改或终止条款。

危险信号 验收标准只有“用户满意”；指标只在测试环境测；目标值拍脑袋，没有现状基线。

D3 做过小范围真实试点并复盘吗？

检查问题 有没有让真实用户在真实工作里连续使用两周以上？收集了哪些使用数据和反馈？改了什么？试点结论是什么？

为什么重要 AI 产品的真实体验和实验室差距很大。小范围试点能以最低成本暴露流程、权限、使用习惯问题，避免全公司上线后才发现方向错了。

通过标准 选择 1 个团队或 10–30 名用户试点不少于 2 周；有使用日志和每周复盘；试点问题清单闭环率不低于 80%；试点通过后再决定扩量。

危险信号 直接全公司上线；试点用户是“被安排”的，实际不用；只看满意度问卷，不看真实使用数据。

上线与运维

上线不是终点
能运维才算交付

05 上线与运维

E1–E3

E1 有灰度、回滚和降级方案吗?

检查问题 上线第一天出问题，多久能回滚？回滚后用户看到什么？旧流程还能不能用？谁能一键停用？

为什么重要 AI 系统的不确定性高于传统系统。没有回滚方案，一次事故就可能让项目被永久叫停，团队之后也不敢再碰 AI。

通过标准 灰度策略明确（按用户/流量/部门）；回滚时间不超过 30 分钟且有演练记录；新旧流程并行不少于 2 周；降级到人工的开关可一键操作。

危险信号 “先上线，出问题再说”；没有版本管理；回滚需要改代码重新发版。

E2 日志、追踪、成本和质量监控是否齐全?

检查问题 用户问了什么、模型答了什么、花了多少 token、哪里失败了，能不能查到？出问题能不能定位到具体一次调用？成本异常能不能及时告警？

为什么重要 AI 系统的故障往往不是宕机，而是“答得越来越差”或“成本悄悄翻倍”。没有可观测性，就无法运维，也无法持续优化。

通过标准 每次调用记录 request_id、用户、模型版本、提示词版本、token、延迟、状态；每日或每周质量抽检；成本和错误率有告警；日志脱敏并按规定保留。

危险信号 只监控服务器 CPU 和内存；日志里明文存客户数据；月底看到账单才发现成本失控。

E3 上线后的运营责任和迭代机制明确吗?

检查问题 上线后谁维护提示词、谁更新知识库、谁处理用户反馈、多久迭代一次？出问题找谁？

为什么重要 AI 应用不是交付即结束。数据会变、模型会升级、用户会提新问题。没有运营机制，三个月后效果一定衰减，最后变成“上线即废弃”。

通过标准 指定运营负责人和值班机制；知识库更新有 SOP（频率、审核人）；用户反馈 48 小时内响应；每月一次效果复盘和版本迭代计划。

危险信号 项目上线后团队解散；知识库半年没更新；用户反馈无人认领。

打分表 SCORING SHEET · 0 / 1

编号	检查项	得分
01 业务价值		
A1	场景能否说清“谁、在什么环节、把什么变成什么”	☐
A2	投入产出账能否算清	☐
A3	是否有对业务结果负责的 Owner	☐
02 数据与权限		
B1	数据来源、更新频率、责任人是否明确	☐
B2	权限是否最小必要隔离并继承源系统	☐
B3	数据合规评估是否完成	☐
03 模型与提示词		
C1	模型选型是否有依据且可替换	☐
C2	提示词是否版本化、可回归、有边界	☐
C3	模型不确定时是否有兜底路径	☐

编号	检查项	得分
04 评测与验收		
D1	是否有来自真实业务的评测集	☐
D2	验收指标是否量化并写进项目书	☐
D3	是否做过小范围真实试点并复盘	☐
05 上线与运维		
E1	是否有灰度、回滚和降级方案	☐
E2	是否有日志、追踪、成本与质量监控	☐
E3	是否有运营责任与迭代机制	☐
合计		
—	**总分 = 15 条得分相加**	____

0–5 分
未就绪
先补业务定义、数据与权限基础，暂不开发。

6–10 分
可试点
限定 1 个团队、1 个流程，小范围验证 2 周以上。

11–13 分
可上线
灰度上线，保留回滚与人工兜底，每月复评。

14–15 分
优秀
可扩大范围，并沉淀为组织级方法与模板。

一票否决： B2（权限隔离）、B3（数据合规）任一条为 0，无论总分多少都不能上线；A1（场景定义）为 0，先不要开发；D1（真实评测集）、D2（量化验收）为 0，只能试点，不得进入生产验收。

怎么用： 3–5 人各自独立打分（20–30 分钟），再集中校准分歧最大的 5 条。

记什么： 每条写清证据；口头“应该没问题”按 0 计。

然后呢： 每个 0 分项转成“谁、做什么、何时完成、用什么证明”的整改清单。